Projetos de Curso – Processamento Digital de Imagens

Quatro propostas com pipeline completo de PDI

Prof. Dr. Ricardo J. Ferrari

Departamento de Computação – UFSCar

Projeto 1 – Classificação de variedades de arroz

Problema. Desenvolver um sistema que segmente o grão, descreva sua morfologia, cor e textura e classifique sua variedade usando métodos clássicos de aprendizado de máquina.

Questão de projeto

- Quanto da discriminação entre variedades pode ser obtida por **atributos interpretáveis** de forma e textura?
- Como erros na segmentação alteram os atributos e a classificação final?

Saída esperada

- máscara do grão;
- vetor de atributos;
- classe estimada;
- análise dos erros.

Base sugerida: Rice Image Dataset 75.000 imagens, 5 variedades (Arborio, Basmati, Ipsala, Jasmine e Karacadag).

`https://www.kaggle.com/datasets/muratkokludataset/rice-image-dataset`

Projeto 1 – Pipeline sugerido

1. Pré-processamento e segmentação

1. **Denoising:** comparar Gaussiano e mediana.
2. **Bordas:** Sobel e Canny para caracterizar o contorno.
3. **Morfologia:** abertura/fechamento, preenchimento de buracos e remoção de pequenos componentes.
4. **Segmentação:** Otsu ou limiarização no espaço de cor mais adequado; reter o maior componente conexo.

2. Descrição e classificação

- **Forma:** área, perímetro, eixos maior/menor, razão de aspecto, excentricidade, solidity e circularidade

$$C = \frac{4\pi A}{P^2}.$$

- **Cor:** médias/desvios em RGB, HSV ou Lab.
- **Textura:** LBP e/ou GLCM.
- **Classificação:** comparar k-NN, SVM e Random Forest.

Regra didática: os atributos devem ser calculados *sobre a região segmentada*, e não sobre a imagem inteira.

Projeto 1 – Experimentos e avaliação

Experimentos mínimos

- Comparar pelo menos **2 métodos de denoising**.
- Comparar Sobel e Canny para a estabilidade do contorno.
- Avaliar como a segmentação altera área, perímetro e circularidade.
- Comparar três conjuntos de atributos: *forma*, *forma+cor* e *forma+cor+textura*.
- Comparar pelo menos **2 classificadores**.

Métricas e entregáveis

- classificação: acurácia balanceada, F1 macro e matriz de confusão;
- validação: divisão estratificada ou validação cruzada;
- segmentação: inspeção visual sistemática e, opcionalmente, anotação manual de um pequeno subconjunto para Dice/IoU;
- relatório com exemplos de acertos e falhas do pipeline.

Extensão opcional: avaliar seleção de atributos e importância de variáveis no Random Forest.

Projeto 2 – Folhas de plantas e condição fitopatológica

Problema. Segmentar a folha e extrair descritores de forma, cor e textura para classificar a condição visual da planta. Para manter o problema controlável, recomenda-se trabalhar com **uma espécie** e 3–5 classes (incluindo saudável).

Questão de projeto

- Quais atributos clássicos são mais informativos para separar folhas saudáveis de folhas com diferentes padrões de doença?
- A segmentação da folha melhora a robustez dos atributos de cor e textura?

Sugestão de recorte

- escolher apenas tomate, batata, maçã etc.;
- balancear as classes;
- evitar classes muito pequenas.

Base sugerida: PlantVillage

Mais de 54 mil imagens de folhas saudáveis e doentes, organizadas por espécie e condição.

`https://data.mendeley.com/datasets/tywbtsjrjv/1`

Projeto 2 – Pipeline sugerido

1. Localização da folha

1. **Denoising:** Gaussiano, mediana ou bilateral.
2. **Bordas:** Sobel/Canny para avaliar a definição do contorno foliar.
3. **Morfologia:** fechamento, preenchimento de buracos, eliminação de pequenos objetos.
4. **Segmentação:** HSV/Lab + Otsu, limiar adaptativo ou k-means.

2. Atributos da região segmentada

- **Forma:** área, perímetro, circularidade, excentricidade, solidity, convexidade.
- **Cor:** histogramas e momentos nos canais HSV/Lab.
- **Textura:** LBP e GLCM (contraste, homogeneidade, energia, correlação).
- **Opcional:** segmentar regiões de aparência lesionada dentro da folha.
- **Classificação:** SVM, Random Forest e/ou k-NN.

Cuidado metodológico: separar treino/teste antes de qualquer seleção de atributos ou ajuste de parâmetros.

Projeto 2 – Experimentos e avaliação

Experimentos mínimos

- Comparar duas estratégias de segmentação da folha.
- Estudar impacto do espaço de cor: RGB vs. HSV ou Lab.
- Comparar atributos de **cor**, **textura** e a combinação dos dois.
- Testar se atributos de forma ajudam ou apenas identificam a espécie.
- Comparar pelo menos dois classificadores.

Métricas e análise

- F1 macro e matriz de confusão;
- sensibilidade/especificidade por classe quando pertinente;
- ablação de atributos;
- análise de imagens difíceis: iluminação, lesões pequenas, fundo residual;
- discutir possíveis vieses do fundo relativamente controlado da base.

Extensão opcional: selecionar manualmente um pequeno subconjunto e produzir máscaras de lesões para avaliar uma segunda etapa de segmentação.

Projeto 3 – Segmentação e classificação de leucócitos

Problema. Segmentar estruturas celulares relevantes (núcleo e, quando viável, citoplasma), extrair atributos morfológicos/cromáticos/texturais e classificar o tipo de leucócito.

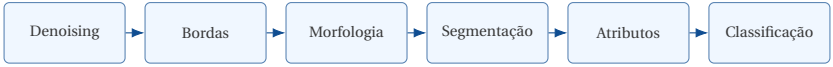

Classes principais

- neutrófilo, eosinófilo, basófilo;
- linfócito e monócito.

Questão de projeto: até que ponto a razão núcleo/citoplasma, a forma nuclear e a textura permitem a classificação com métodos tradicionais?

Saídas intermediárias

- máscara do núcleo;
- máscara da célula/citoplasma;
- contorno e medidas;
- classe estimada.

Base sugerida: Raabin-WBC

`https://raabindata.com/free-data/`

Mais de 40 mil imagens de cinco tipos de leucócitos; acesso gratuito no portal oficial.

Projeto 3 – Pipeline sugerido

1. Segmentação celular

1. **Denoising:** mediana, bilateral ou Gaussiano leve.
2. **Bordas:** Sobel/Canny como informação complementar para limites nucleares/celulares.
3. **Espaço de cor:** RGB → Lab/HSV para aumentar separação cromática.
4. **Segmentação:** Otsu, k-means ou limiarização por canal para núcleo; estimativa da célula completa em segunda etapa.
5. **Morfologia:** abertura/fechamento, preenchimento de buracos, remoção de

2. Descritores e classificação

- núcleo: área, perímetro, excentricidade, circularidade, número de lóbulos aproximado;
- **razão núcleo/citoplasma**;
- cor: médias e histogramas por região;
- textura: LBP/GLCM no núcleo e citoplasma;
- classificação: SVM e Random Forest como referências principais.

Projeto 3 – Experimentos e avaliação

Experimentos mínimos

- Comparar pelo menos duas estratégias de segmentação do núcleo.
- Avaliar robustez a variações de coloração e contraste.
- Comparar: atributos do núcleo vs. núcleo+citoplasma.
- Fazer ablação de forma, cor e textura.
- Avaliar desempenho por classe, não apenas acurácia global.

Métricas e cuidados

- F1 macro, recall por classe e matriz de confusão;
- Dice/IoU se forem utilizadas máscaras de referência disponíveis no subconjunto escolhido;
- evitar mistura de imagens altamente semelhantes entre treino e teste;
- documentar falhas de segmentação antes de interpretar erros do classificador.

Extensão opcional: estudar quais características morfológicas mais contribuem para distinguir granulócitos e células mononucleares.

Projeto 4 – Detecção e classificação de defeitos industriais

Problema. Localizar regiões anômalas em imagens de produtos industriais, descrevê-las por atributos clássicos e classificar a amostra como normal/defeituosa ou, quando possível, por tipo de defeito.

Escopo recomendado

- escolher **uma única categoria** de objeto (por exemplo: bottle, capsule, hazelnut, metal_nut ou pill);
- concentrar o projeto nos defeitos daquela categoria e usar as máscaras de referência para avaliar a localização.

Questão de projeto

É possível detectar e classificar defeitos usando apenas processamento clássico e atributos interpretáveis?

Base sugerida: MVTec AD Mais de 5.000 imagens, 15 categorias; imagens normais/defeituosas e máscaras precisas dos defeitos.

`https://www.mvtec.com/research-teaching/datasets/mvtec-ad`

Projeto 4 – Pipeline sugerido

1. Localização do objeto/defeito

1. **Denoising:** Gaussiano, mediana ou bilateral, conforme a categoria.
2. **Bordas:** Sobel/Canny para realçar descontinuidades e estrutura do objeto.
3. **Morfologia:** fechamento/abertura e remoção de componentes pequenos.
4. **Segmentação:** limiarização, diferença em relação a uma referência, k-means ou segmentação por regiões.
5. comparar a máscara estimada com a **máscara ground truth**.

2. Descrição e decisão

- geometria do defeito: área, perímetro, extensão, orientação;
- intensidade/cor: médias, desvios, histogramas;
- textura: LBP e GLCM;
- atributos do contorno e HOG quando adequados;
- classificação: normal/defeituoso ou tipo de defeito usando SVM/RF.

Obs.: uso didático – crie sua própria partição supervisionada; não reporte os resultados como benchmark oficial do MVTec AD.

Projeto 4 – Experimentos e avaliação

Experimentos mínimos

- Comparar duas estratégias de segmentação/localização do defeito.
- Quantificar o efeito de operações morfológicas sobre falsos positivos.
- Comparar atributos geométricos, textura e combinação completa.
- Comparar pelo menos dois classificadores.
- Separar resultados por tipo de defeito.

Métricas e entregáveis

- segmentação: Dice, IoU, precisão e recall pixel a pixel;
- classificação: F1, balanced accuracy, ROC-AUC para normal/defeituoso;
- exemplos de falsos positivos e falsos negativos;
- discussão sobre quais etapas do pipeline mais limitam o desempenho.

Extensão opcional: estudar se os atributos extraídos apenas dentro da região defeituosa superam atributos globais da imagem.